

与信スコアリングモデルにおける予測精度と公平性の関係分析

German Credit Dataを用いた機械学習モデルの比較評価

Nguyen Hoang(グエン ホアン)、池田 孝利 | 大和大学 池田研究室 | 2026年3月29日

1. 研究目的・データセット

研究目的

機械学習モデルの予測精度と公平性(年齢・性別)の関係を定量評価

✓ モデル比較: LR, RF, XGBoost

✓ 公平性: DP, EO

✓ SHAP解析

✓ Cross-Validation

データセット


• German Credit (UCI), N=1,000

• Features: 20個

• Protected: Age (≤ 25 / >25), Sex (M/F)

3. モデル比較結果 (5-Fold CV)

Model Comparison: Accuracy vs Fairness Trade-off



重要発見

1. **トレードオフなし**XGB 76.4% + 3.68% 両立

2. **Tree-based優位**性別バイアス LR→XGB半減

3. **CV安定性確認**

2. 先行研究と本研究の位置づけ

先行研究の課題

✗ **Trade-offの前提** [1][2]

✗ **単一モデル評価**

✗ **定性的バイアス分析** [3]

本研究の貢献

✓ **Trade-offなしの実証**XGB: 76.4% + 3.68%両立

✓ **3モデル系統的比較**


✓ **SHAP要因特定**

先行研究との差分・意義

Hardt [1]がDP/EO定義、Chouldechova [3]が同時達成不可能性を示したが、本研究はSHAPで要因分析を加え間接的バイアスを実証した点が新規性。

4. SHAP解析: バイアス要因

SHAP Feature Importance (Top 15)



バイアス方向と仮説

年齢: Old>Young (+2.73%)

性別: Female>Male (+7.56%)

最有力仮説: 信用品質プロキシ

→ 当座預金残高 (SHAP=0.791) が主因

→ **データ起因 (モデル起因でない)**

【結果】

グループ	承認率	DP Gap	EO Gap	判定
Old (>25)	74.2%	—	—	✓
Young (≤ 25)	71.5%	2.73%	2.1%	✓
Male	70.2%	—	—	✓
Female	77.7%	7.56%	5.4%	✓

6. 結論・限界・今後

結論

1. **両立可能**XGB 76.4% + 3.68%

2. **直接影響小** Age・Sex下位ランク

3. **実務表示** Tree-based + 代替データ

限界

• N=1,000 限定

• 単一データセット

• 緩和手法未実装

今後

• 大規模検証 (N $\geq 100k$)

• 緩和手法評価

• 追加指標検証

参考文献

[1] Hardt, M., et al. (2016). Equality of opportunity in supervised learning. NeurIPS.

[2] Barocas, S., & Selbst, A. D. (2016). Big data's disparate impact. California Law Review, 104.

[3] Chouldechova, A. (2017). Fair prediction with disparate impact. Big Data, 5(2).

[4] Bartlett, R., et al. (2019). Consumer-lending discrimination in the FinTech era. NBER.

[5] Fuster, A., et al. (2022). Predictably unequal? Journal of Finance, 77(1).