

与信スコアリングモデルにおける 予測精度と公平性の関係分析

German Credit Dataを用いた機械学習モデルの比較評価

グエンホアン、池田孝利 | 大和大学 池田研究室 | 2026年3月29日

1. 研究目的・データセット

研究目的

機械学習モデルの予測精度と公平性(年齢・性別)の関係を定量評価する

- ✓ モデル比較: LR, RF, XGBoost
- ✓ 公平性指標: DP, EO
- ✓ SHAP解析: バイアス要因特定
- ✓ Cross-Validation: 安定性検証

データセット仕様

- Dataset: German Credit Data (UCI)
- Sample size: 1,000件
- Features: 20個
- Protected: Age (≤ 25 / >25), Sex (M/F)
- Threshold: DP $\leq$ 10%, EO $\leq$ 10%
- Evaluation: 5-Fold CV (random_state=42)

2. 先行研究と本研究の位置づけ



先行研究の課題

- ✗ Accuracy-Fairness Trade-offの前提
 - 多くの研究が両者の対立を仮定
 - 公平性向上 = 精度低下と認識
- ✗ 単一モデル評価が主流
 - 複数モデルの系統的比較不足
- ✗ バイアス要因の定性的分析
 - SHAP等の解釈可能AI手法未活用
- ✗ 単発評価による過剰楽観
 - Cross-Validationによる安定性検証不足

本研究の貢献

- ✓ Trade-offなしの実証
 - XGBoost: 高精度 (76.4%) かつ 低バイアス (3.68%)
 - 両立可能性を定量的に証明
- ✓ 3モデルの系統的比較
 - LR, RF, XGBoostで一貫した評価
- ✓ SHAP解析によるバイアス源特定
 - 当座預金残高 (SHAP=0.791) が主因と判明
- ✓ CV安定性検証
 - Week1単発 1.54% vs Week2 CV平均 5.03%
 - 単発評価の危険性を定量化



3. モデル比較結果 (Week 2: 5-Fold Cross-Validation)



重要発見

- トレードオフなし
XGBoost: 最高精度 76.4% かつ 最低性別バイアス 3.68%
- Tree-basedモデルの優位性
性別バイアス: LR 6.14% → XGB 3.68% (半減)
- CV安定性
RF: 最小標準偏差 (Accuracy Std=1.2%)
XGB: Age bias変動大 (Std=5.7%)

4. SHAP解析: バイアス要因の特定 (Week 3)



公平性指標サマリー (XGBoost)

グループ	承認率	DP Gap	判定
グループ	承認率	DP Gap	判定
Old (>25)	74.2%	—	✓
Young (≤25)	71.5%	2.73%	✓
Male	70.2%	—	✓
Female	77.7%	7.56%	✓

Note: Week1単発 DP_Age=1.54% → Week2 CV平均 5.03% (Lucky split検証)

△ バイアス方向と主仮説

年齢: Old > Young (+2.73%) | 性別: Female > Male (+7.56%)

最有力仮説: 信用品質プロキシ効果

→ 当座預金残高 (SHAP=0.791) が構造的な不平等を反映

→ データ起因のバイアス (モデル起因ではない)

5. 結論・限界・今後の展望

結論: 5つの主要発見

- トレードオフなし
XGBoost: 高精度 (76.4%) + 低性別バイアス (3.68%) 両立
- Tree-basedモデルの優位性
性別バイアス半減: LR 6.14% → XGB 3.68%
- データ起因バイアス
当座預金残高 (SHAP=0.791) が主因
- CV必須
Week1単発 1.54% vs Week2 CV 5.03% → 楽観性
- 性別バイアス逆転
Female > Male (+7.56%) 女性の信用度高

限界

- 単一データセット (N=1,000)
- 年齢バイアス不安定性 (Std=5.7%)
- バイアス緩和手法未実装
- DP・EOのみ評価 (他指標未検証)
- 相関分析のみ (因果関係未確定)

今後の展望 (6ヶ月計画)

- 4月: South German Credit追加 (N→2,000)
- 5月: 公平性緩和手法 (Reweight/調整)
- 6月: 追加指標 (Equalized Odds/Calibration)
- 7月: 因果推論分析 (Pearl手法)
- 8-9月: 論文執筆・学会投稿

【公平性指標定義】

- Demographic Parity (DP):
 $DP = |P(Y=1|A=0) - P(Y=1|A=1)|$
- Equal Opportunity (EO):
 $EO = |TPR(A=0) - TPR(A=1)|$

【Repository】

github.com/ikedalab-org/
nguyen-credit-fairness-2026

技術仕様・再現性

【ソフトウェア環境】

- Python ≥3.8
- scikit-learn ≥1.3.0
- XGBoost ≥2.0.0
- SHAP ≥0.44.0
- random_state=42 (全実験固定)